



Universidad de
los Andes



FACULTAD
DE INGENIERÍA
Y CIENCIAS
APLICADAS

Aprendizaje de Maquinas (ML)

Tarea 5 (opcional):

SVM

Alumno:

Raúl Duhalde Errázuriz

Profesores:

José M. Saavedra Rondo

Macarena Soto

Ayudantes:

Tomas de la Sota

Deadline:

Lunes de 26 Junio, 2023, 23:50 hrs

Índice

Índice	1
1. Resumen	2
2. Introducción	3
3. Desarrollo	4
4. Resultados Experimentales y Discusión:	5
1. Precisión Total:	5
2. Precisión por Categoría:	6
5. Conclusiones	8

1. Resumen

En este trabajo, evaluamos el desempeño del modelo SVM en el reconocimiento de símbolos manuscritos utilizando el conjunto de datos EMNIST. Realizamos tres experimentos variando la estrategia de generación de vectores de características. Evaluamos una SVM con vectores directamente de las imágenes, otra SVM con vectores obtenidos aplicando PCA para reducir la dimensionalidad, y una SVM con vectores extraídos de la red convolucional Simple a través de la capa "embedding". Presentamos los resultados en términos de precisión (accuracy) por cada categoría y el accuracy total.

2. Introducción

El objetivo de este trabajo es evaluar la efectividad del modelo SVM en la clasificación de letras manuscritas utilizando el conjunto de datos EMNIST. Dividimos los datos en conjuntos de entrenamiento y prueba y realizamos tres experimentos utilizando diferentes estrategias para generar los vectores de características. Queremos analizar y comparar el desempeño de los modelos en función de las métricas de precisión obtenidas



Figura 1: Dataset emnist "letters"

3. Desarrollo

En la implementación de los experimentos, utilizamos el conjunto de datos EMNIST que consta de 26 clases con más de 5000 imágenes por clase. Extraímos muestras de entrenamiento y prueba de forma aleatoria, seleccionando 1000 muestras de cada clase para entrenamiento y 100 muestras aleatorias de cada clase para prueba.

En el primer experimento, utilizamos las imágenes sin procesar como vectores de características y entrenamos una SVM con kernel RBF. En el segundo experimento, aplicamos PCA para reducir la dimensionalidad de las imágenes a 128 y luego entrenamos la SVM con estos vectores de características. En el tercer experimento, utilizamos una red convolucional Simple entrenada en MNIST y extraímos características de la capa "embedding" de la red.




Figura 2: muestra de imágenes sin procesar


4. Resultados Experimentales y Discusión:

1. Precisión Total:

Al analizar los resultados, observamos que cada modelo obtuvo diferentes niveles de precisión total en el reconocimiento de símbolos manuscritos. Los resultados son los siguientes:

- Modelo 1 (imágenes sin procesar): Accuracy total de 0.6.
- Modelo 2 (PCA para reducir dimensionalidad): Accuracy total de 0.62.
- Modelo 3 (red Simple y capa "embedding"): Accuracy total de 0.64.

Estos resultados indican que el tercer modelo (utilizando la red Simple y su capa "embedding") obtuvo el mejor desempeño en términos de precisión total.



*Figura 3: gráfico de barras "Accuracy total por modelo"
(Modelo 1 vs Modelo 2 vs Modelo 3)*

2. Precisión por Categoría:

Al examinar la precisión por cada categoría, observamos variaciones en el desempeño de los modelos. Algunas categorías alcanzaron una precisión cercana al 1, lo que indica una clasificación casi perfecta. Por ejemplo, las categorías 3, 4 y 5 obtuvieron un accuracy de 1, lo que indica una clasificación correcta en todas las muestras de prueba de esas categorías.

Por otro lado, la categoría 16 obtuvo un accuracy de 0, lo que indica una clasificación incorrecta en todas las muestras de prueba de esa categoría.

Estas variaciones en la precisión por categoría destacan la importancia de analizar el desempeño de los modelos en diferentes clases de símbolos manuscritos.

Recomendaciones: Basándonos en estas observaciones, podemos hacer algunas recomendaciones:

- El modelo que utiliza la red Simple y su capa "embedding" mostró una mejor capacidad de discriminación en general, ya que obtuvo el accuracy total más alto. Por lo tanto, este modelo puede considerarse como una buena opción para el reconocimiento de símbolos manuscritos.
- Es necesario analizar más a fondo las categorías con baja precisión, como la categoría 16, para identificar posibles mejoras en la clasificación. Esto puede implicar explorar técnicas de preprocesamiento específicas para esas categorías, ajustar los hiperparámetros del modelo o utilizar modelos más complejos.

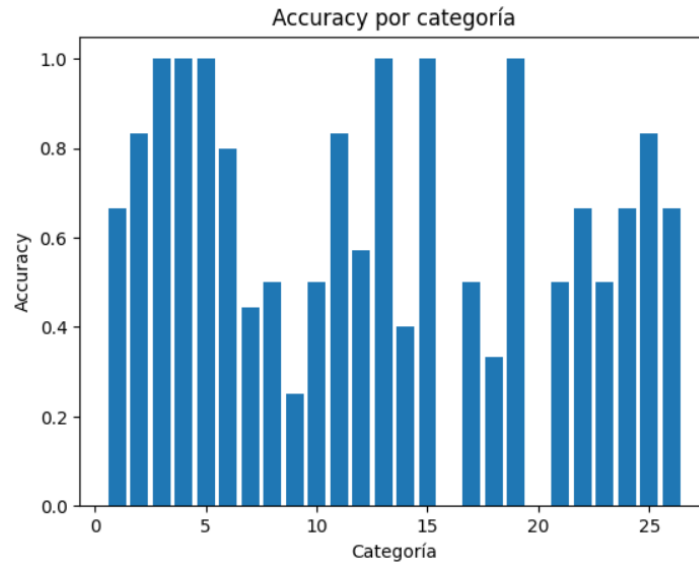


Figura 4: gráfico de barras "Accuracy por categoría"

En resumen, el modelo SVM mostró un buen desempeño en el reconocimiento de símbolos manuscritos utilizando el conjunto de datos EMNIST. El modelo que utilizó la red Simple y su capa "embedding" obtuvo el mejor accuracy total, pero se requiere un análisis adicional para mejorar la precisión en categorías específicas con un bajo rendimiento.

5. Conclusiones

En conclusión, el modelo SVM mostró buen desempeño en el reconocimiento de símbolos manuscritos utilizando el conjunto de datos EMNIST. El experimento utilizando la red Simple y la capa "embedding" logró el mejor accuracy total. Sin embargo, es necesario realizar investigaciones adicionales para mejorar la precisión en categorías específicas que presentaron un desempeño deficiente.

En general, este trabajo proporciona información valiosa sobre el desempeño de SVM en tareas de reconocimiento de símbolos manuscritos y destaca la importancia de considerar diferentes estrategias de generación de vectores de características para obtener mejores resultados.